



**FACULTAD DE INGENIERÍA
ESCUELA DE INGENIERÍA CIVIL BIOMÉDICA**

***MACHINE LEARNING CAUSAL EN RESONANCIA
MAGNÉTICA FUNCIONAL***

CRISTIAN RAÚL SALGADO TORRES

Trabajo para optar al Título de
Ingeniero Civil Biomédico

Julio - 2026

VALPARAÍSO ::: CHILE



Universidad de Valparaíso
Facultad de Ingeniería
Escuela de Ingeniería Civil Biomédica

Nota:

El presente trabajo constituye un requisito parcial en el contexto de la asignatura “CBM621 Proyecto de Ingeniería Biomédica”, por lo tanto no constituye una tesis formal ni un trabajo público.

La comisión estuvo integrada por:

- Profesor guía: Alejandro Veloz
- Profesor corrector: César Galindo

Dedicatoria

A quienes creyeron en este proceso incluso cuando el camino no era claro.

“La causalidad es la base de toda comprensión científica.”

(Judea Pearl)

Agradecimientos

Agradezco al profesor Alejandro Veloz por la orientación y motivación durante el desarrollo de esta investigación, así como al profesor César Galindo por sus observaciones y aportes al trabajo. Igualmente, agradezco a mi familia y compañeros por el apoyo constante a lo largo de esta etapa.

Índice

1	INTRODUCCIÓN	1
1.1	Objetivo general	1
1.2	Objetivos específicos	1
2	FUNDAMENTOS	1
2.1	rs-fMRI, señal BOLD y parcelación	1
2.2	Estimadores de conectividad	2
2.3	Clasificación y evaluación	2
3	METODOLOGÍA E IMPLEMENTACIÓN	2
3.1	Conjunto de datos	2
3.2	Preprocesamiento	2
3.3	Parcelación cerebral y extracción de ROIs	2
3.4	Covariables y control de movimiento	3
3.5	Inferencia estadística	3
3.6	Estimación de conectividad	3
3.6.1	<i>Correlación de Pearson</i>	3
3.6.2	<i>Graphical Lasso</i>	3
3.6.3	<i>LiNGAM</i>	4
3.7	Vectorización de matrices	4
3.8	Clasificación	4
3.9	Evaluación y comparación entre métodos	4
4	RESULTADOS	5
4.1	Descripción de la cohorte	5
4.2	Matrices promedio	5
4.3	Inferencia estadística ajustada	6
4.4	Distribuciones por sujeto	7
4.5	Resultados de clasificación	8
5	DISCUSIÓN	9
5.1	Efecto del método de conectividad	9
5.2	Covariables, movimiento y estabilidad	9
5.3	LiNGAM y clasificación	9
6	CONCLUSIÓN	10

MACHINE LEARNING CAUSAL EN RESONANCIA MAGNÉTICA FUNCIONAL

Cristian Raúl Salgado Torres

Escuela de Ingeniería Civil Biomédica
Facultad de Ingeniería, Universidad de Valparaíso, Chile

Resumen: El análisis del TEA mediante rs-fMRI requiere comparar estimadores asociativos y dirigidos para establecer qué tipo de representación caracteriza mejor las diferencias de conectividad entre TEA y controles. Se implementó un pipeline con datos de ABIDE I, atlas Schaefer 100 y 723 sujetos (329 TEA y 394 controles), en el que se estimaron matrices mediante correlación de Pearson, Graphical Lasso y LiNGAM. Tras ajustar Pearson y Graphical Lasso por edad, sexo, movimiento medio y sitio de adquisición, con control FDR y evaluación mediante Network-Based Statistic, Pearson con SVM alcanzó una balanced accuracy de 0,640 (IC95 %: 0,589–0,675), Graphical Lasso con Random Forest alcanzó un AUC de 0,686 (IC95 %: 0,632–0,738) y LiNGAM obtuvo un desempeño cercano o inferior al azar. La comparación permite delimitar el alcance descriptivo y predictivo de los métodos sin proponer causalidad demostrada ni biomarcadores clínicos.

Palabras Clave (máximo 5): rs-fMRI, BOLD, conectividad funcional, conectividad dirigida, aprendizaje automático.

1 INTRODUCCIÓN

El trastorno del espectro autista (TEA) afecta aproximadamente a 1 de cada 127 personas a nivel mundial, según estimaciones de la Organización Mundial de la Salud para 2021 [1]. Se caracteriza por alteraciones en la comunicación social y patrones de comportamiento restrictivos y repetitivos. Su diagnóstico es clínico y depende de evaluaciones conductuales, lo que ha impulsado la búsqueda de marcadores complementarios basados en neuroimagen. La resonancia magnética funcional en reposo (rs-fMRI) permite estudiar la organización funcional intrínseca del cerebro sin necesidad de una tarea activa, y ha mostrado diferencias sistemáticas en la conectividad cerebral entre personas con TEA y controles [2, 3].

Los métodos más utilizados para estimar conectividad funcional, como la correlación de Pearson y Graphical Lasso, cuantifican relaciones estadísticas entre regiones cerebrales, pero no permiten inferir dirección ni causalidad [4, 5]. Esta limitación es relevante porque dos regiones pueden presentar una alta asociación debido a una influencia común de una tercera área, a ruido compartido durante la adquisición o a efectos indirectos del preprocesamiento, sin que necesariamente exista una conexión funcional directa entre ellas. En este sentido, la conectividad efectiva —que busca representar influencias dirigidas entre regiones— ofrece una perspectiva complementaria para la caracterización de las interacciones cerebrales [6].

Dentro de los métodos orientados al descubrimiento causal, LiNGAM permite estimar relaciones dirigidas entre variables observacionales bajo supuestos de linealidad, aciclicidad y no gaussianidad de los errores [7]. Su aplicación en rs-fMRI resulta particularmente interesante, ya que permite explorar si la incorporación de información direccional aporta características útiles para distinguir TEA y controles. Sin embargo, este enfoque también presenta desafíos importantes, debido a que la señal BOLD es una medida indirecta y temporalmente suavizada de la actividad neuronal, y a que la alta dimensionalidad de las matrices de conectividad puede dificultar la estimación estable de relaciones dirigidas con tamaños muestrales limitados. En este contexto, se comparan la correlación de Pearson, Graphical Lasso y LiNGAM en datos rs-fMRI de ABIDE I para evaluar si la repre-

sentación dirigida aporta información complementaria frente a los métodos asociativos, tanto en la caracterización de los patrones de conectividad como en la clasificación de TEA y controles.

1.1 Objetivo general

Comparar matrices de conectividad cerebral estimadas mediante correlación de Pearson, Graphical Lasso y LiNGAM en datos rs-fMRI de ABIDE I, evaluando diferencias entre TEA y controles y su utilidad preliminar para clasificación supervisada.

1.2 Objetivos específicos

- Extraer señales BOLD regionales mediante el atlas Schaefer 100 y construir matrices de conectividad de 100×100 por sujeto.
- Estimar conectividad mediante correlación de Pearson, Graphical Lasso y LiNGAM, manteniendo una lectura asociativa para los dos primeros métodos y dirigida exploratoria para LiNGAM.
- Comparar TEA y controles mediante modelos ajustados por covariables, corrección FDR y *Network-Based Statistic*.
- Evaluar el desempeño de clasificación supervisada (SVM y Random Forest) para cada método de conectividad, con el fin de determinar si la representación dirigida de LiNGAM aporta información complementaria frente a los métodos asociativos.

2 FUNDAMENTOS

2.1 rs-fMRI, señal BOLD y parcelación

La rs-fMRI caracteriza fluctuaciones espontáneas de la señal BOLD y permite estimar dependencias estadísticas entre regiones cerebrales [8, 2, 3]. La señal BOLD refleja cambios hemodinámicos asociados

indirectamente con la actividad neuronal; por tanto, su resolución temporal está limitada por una respuesta vascular lenta y variable [9, 10, 11].

El atlas Schaefer 100 divide la corteza en 100 regiones agrupadas en siete redes funcionales [12]. La resolución elegida mantiene una representación anatómica interpretable y limita la dimensionalidad. El atlas, el orden de las regiones y las señales de entrada se mantienen constantes en los tres estimadores.

2.2 Estimadores de conectividad

La correlación de Pearson cuantifica asociación lineal bivariada y produce una matriz simétrica de conectividad funcional. Graphical Lasso estima una matriz de precisión regularizada y, a partir de ella, correlaciones parciales que resumen dependencias condicionales más dispersas [13, 14]. Ambos métodos describen asociaciones y no permiten inferir dirección o causalidad [4, 6].

LiNGAM estima un grafo dirigido bajo supuestos de linealidad, aciclicidad, independencia y no gaussianidad de los errores [7]. Tales supuestos son difíciles de garantizar en rs-fMRI debido a la respuesta hemodinámica, los posibles confundentes no observados y la retroalimentación biológica. Se incluye como contraste metodológico para comprobar si esa representación aporta información reproducible; no se interpreta como conectividad causal demostrada.

2.3 Clasificación y evaluación

Las matrices simétricas se vectorizan mediante su triángulo superior y las matrices dirigidas conservan las conexiones ordenadas. Se comparan SVM con kernel RBF y Random Forest, dos clasificadores habituales para datos de alta dimensionalidad [15, 16, 17]. La evaluación prioriza *balanced accuracy* y AUC, complementadas por sensibilidad y especificidad. Las curvas ROC resumen el compromiso entre verdaderos y falsos positivos [18, 19, 20]. Ambos clasificadores son adecuados para espacios de características de alta dimensionalidad con muestras limitadas, mientras que los pesos balanceados por clase reducen el efecto del desbalance entre 329 sujetos TEA y 394 controles.

3 METODOLOGÍA E IMPLEMENTACIÓN

3.1 Conjunto de datos

Se utiliza el conjunto Autism Brain Imaging Data Exchange (ABIDE I), una base de datos pública de resonancia magnética funcional en reposo (rs-fMRI) que reúne datos provenientes de múltiples sitios de adquisición [21]. Se incluyen sujetos con diagnóstico de trastorno del espectro autista (TEA) y controles, con el objetivo de evaluar si las matrices de conectividad cerebral permiten diferenciar ambos grupos mediante modelos de aprendizaje automático.

Los criterios de inclusión consideraron la disponibilidad de imágenes funcionales preprocesadas en ABIDE PCP, la existencia de información diagnóstica asociada, la disponibilidad del archivo funcional en la rama *filt_noglobal*, la extracción válida de señales regionales para el atlas Schaefer 100 y una longitud mínima de 146 puntos temporales. El pipeline identificó 871 sujetos con parcelación válida antes del filtro temporal y excluyó 148 por presentar menos de 146 volúmenes. No se registraron exclusiones adicionales por matrices faltantes o inválidas en la cohorte final. En la corrida principal se incluyeron 723 sujetos, correspondientes a 329 sujetos TEA y 394 controles. Debido a que ABIDE I es una base multicéntrica, los datos pueden presentar diferencias entre sitios, tales como variaciones en

el tiempo de repetición (TR), número de volúmenes, parámetros de adquisición y características demográficas de los participantes. Por esta razón, el análisis se realiza manteniendo un mismo procedimiento de extracción de señales, estimación de conectividad, vectorización y clasificación para todos los sujetos incluidos.

3.2 Preprocesamiento

El análisis utiliza imágenes funcionales preprocesadas por ABIDE PCP mediante C-PAC [22, 23]. Estas imágenes corresponden a archivos *func_preproc* de la rama filtrada sin regresión global (*filt_noglobal*), por lo que la corrida principal no aplica un filtrado temporal local adicional sobre los NIfTI. En términos generales, el preprocesamiento previo considera etapas habituales en estudios de rs-fMRI, incluyendo corrección de movimiento, registro al espacio estándar, normalización espacial y reducción de fuentes de ruido asociadas a artefactos de adquisición. El movimiento residual se conserva como covariable porque puede inducir asociaciones sistemáticas en matrices de conectividad funcional [24, 25].

Después de la parcelación, las señales regionales utilizadas por el pipeline son estandarizadas mediante *z-score*, de modo que cada serie temporal tenga media cero y varianza unitaria. Esta normalización permite que las estimaciones de conectividad no dependan directamente de la escala original de la señal BOLD y facilita la comparación entre sujetos y regiones cerebrales. Además, se excluyen sujetos con menos de 146 puntos temporales para mantener una longitud temporal mínima común y cumplir $T > K$ para LiNGAM con 100 ROIs. Este umbral constituye un criterio operacional mínimo y no asegura por sí mismo la estabilidad de las estimaciones estadísticas o causales.

3.3 Parcelación cerebral y extracción de ROIs

Las señales BOLD preprocesadas se parcelan utilizando el atlas Schaefer 100, una parcelación funcional que divide la corteza cerebral en 100 regiones de interés. Esta elección permite trabajar con una resolución moderada, equilibrando la representación funcional del cerebro con una dimensionalidad manejable para la estimación de conectividad y la clasificación supervisada.

Para cada sujeto se extrae una señal temporal representativa por cada región de interés. Esta señal se obtiene promediando la actividad BOLD de los vóxeles pertenecientes a cada ROI, generando una matriz de series temporales:

$$\mathbf{X} \in \mathbb{R}^{T \times K} \quad (1)$$

donde T corresponde al número de volúmenes temporales y $K = 100$ corresponde al número de regiones definidas por el atlas Schaefer 100. Cada columna de la matriz representa la señal temporal de una región cerebral y constituye la base para estimar las matrices de conectividad. En la implementación se exige un mínimo de 100 vóxeles por ROI después del remuestreo al espacio funcional. En la cohorte reportada, las 100 parcelas de Schaefer superaron este criterio y mantuvieron un orden común en todos los sujetos.

La Figura 1 ilustra este paso metodológico con un ejemplo extraído de la corrida principal: una ROI del atlas Schaefer 100 superpuesta sobre un corte funcional, la señal BOLD original de esa región y la matriz ROIs por tiempo, estandarizada mediante *z-score*, utilizada para la construcción posterior de matrices de conectividad. Dado que la rama *filt_noglobal* ya incorpora filtrado temporal, la señal “original” y la señal usada antes del *z-score* coinciden en esta corrida.




Figura 1: Extracción de señales regionales con el atlas Schaefer 100. (A) ROI seleccionada sobre un corte axial funcional. (B) Serie temporal BOLD de la ROI. (C) Matriz ROIs $\times$ tiempo estandarizada mediante z-score, utilizada como entrada para la estimación de conectividad.

El uso de un mismo atlas para todos los métodos permite que la comparación entre correlación de Pearson, Graphical Lasso y LiNGAM sea más justa. De esta forma, las diferencias observadas en las matrices y en el desempeño de clasificación pueden atribuirse principalmente al método de estimación de conectividad, y no a diferencias en la definición de los nodos cerebrales.

3.4 Covariables y control de movimiento

La cohorte se caracteriza mediante edad, sexo, cociente intelectual, desplazamiento cuadro a cuadro medio (*mean framewise displacement*, FD), porcentaje de volúmenes por sobre el criterio de FD y sitio de adquisición. El cociente intelectual se presenta de forma descriptiva, pero no se incorpora al modelo principal debido a sus valores faltantes.

Las comparaciones de conectividad incluyen diagnóstico, edad estandarizada, sexo, FD medio estandarizado y efectos fijos de sitio. Este ajuste reduce la posibilidad de atribuir al diagnóstico diferencias relacionadas con composición demográfica, movimiento residual o adquisición multicéntrica [24, 25].

3.5 Inferencia estadística

Las conexiones de Pearson se transforman mediante z de Fisher antes del ajuste. Para Pearson y Graphical Lasso se estima un modelo lineal por conexión, con TEA codificado como variable indicadora y las covariables descritas previamente. Los valores p se corrigen mediante el procedimiento FDR de Benjamini–Hochberg [26].

La inferencia por conexión se complementa mediante *Network-Based Statistic* (NBS), que evalúa componentes conectados de aristas supraliminales y controla el error a nivel de red [27]. Se utiliza un umbral primario bilateral $|t| \geq 3,1$ y 1000 permutaciones del diagnóstico restringidas dentro de cada sitio. Se consideran significativos los componentes con $p_{NBS} < 0,05$.

La magnitud absoluta media y la esparsidad se calculan primero en cada sujeto. La esparsidad corresponde a la proporción de conexiones con $|M_{ij}| \leq 0,001$. Las diferencias grupales de estas métricas usan el mismo modelo de covariables y corrección FDR.

3.6 Estimación de conectividad

A partir de las series temporales regionales se construyen matrices de conectividad cerebral mediante tres métodos: correlación de Pearson, Graphical Lasso y LiNGAM. Los dos primeros corresponden a métodos asociativos, ya que estiman relaciones estadísticas entre regiones cerebrales sin incorporar dirección. En cambio, LiNGAM se utiliza como una aproximación dirigida exploratoria, orientada a estimar posibles relaciones dirigidas entre regiones.

3.6.1 Correlación de Pearson

La correlación de Pearson se utiliza para estimar la asociación lineal entre pares de regiones cerebrales. Para cada sujeto se calcula una matriz de conectividad simétrica:

$$\mathbf{M}^{Pearson} \in \mathbb{R}^{K \times K} \quad (2)$$

donde cada elemento M_{ij} representa el coeficiente de correlación entre la señal BOLD de la región i y la región j . Los valores de la matriz se encuentran en el intervalo $[-1, 1]$, donde valores positivos indican sincronización directa, valores negativos indican asociación inversa y valores cercanos a cero indican baja asociación lineal.

La matriz resultante es simétrica, ya que la relación entre la región i y la región j es equivalente a la relación entre j e i . Por esta razón, en la etapa de vectorización se utiliza únicamente la parte triangular superior de la matriz, excluyendo la diagonal principal.

3.6.2 Graphical Lasso

Graphical Lasso se utiliza para estimar dependencias condicionales entre regiones cerebrales a partir de la matriz de precisión, definida como la inversa de la matriz de covarianza. A diferencia de la correlación de Pearson, que evalúa relaciones bivariadas, Graphical Lasso considera el conjunto completo de regiones de manera simultánea, permitiendo obtener una red más dispersa e interpretable.

El método estima la matriz de precisión $\hat{\Theta}$ incorporando una penalización ℓ_1 , lo que favorece que algunas conexiones débiles sean reducidas a cero. Esto resulta útil en estudios de conectividad cerebral, donde el número de conexiones puede ser elevado respecto del número de observaciones temporales disponible por sujeto.

En la corrida principal se utilizó $\alpha = 0,5$ como configuración fija

exploratoria. Se realizó una validación técnica piloto con cinco sujetos TEA y cinco controles, evaluando $\alpha \in \{0,05, 0,1, 0,2, 0,3, 0,5\}$ y usando como criterio la proximidad a una densidad no nula objetivo de 0,12. Los valores 0,05 y 0,1 presentaron fallos de convergencia en dos de los diez sujetos, mientras que $\alpha = 0,5$ alcanzó 100% de ajustes válidos y una densidad media de 0,1195. Esta validación sirve como control técnico de la configuración reportada, pero no constituye una optimización formal de hiperparámetros ni una validación externa. Cabe señalar que esta configuración representa una elección técnica exploratoria basada en convergencia numérica y no una optimización formal de hiperparámetros; sus efectos sobre los resultados deben considerarse al interpretar las comparaciones.

A partir de la matriz de precisión estimada, la conectividad entre dos regiones se expresa como una medida normalizada derivada de dicha matriz:

$$M_{ij} = -\frac{\hat{\Theta}_{ij}}{\sqrt{\hat{\Theta}_{ii}\hat{\Theta}_{jj}}} \quad (3)$$

donde $\hat{\Theta}_{ij}$ corresponde al elemento fuera de la diagonal de la matriz de precisión y $\hat{\Theta}_{ii}$, $\hat{\Theta}_{jj}$ corresponden a los elementos diagonales asociados a las regiones i y j . Esta normalización es análoga a una correlación parcial derivada de la matriz de precisión, pero no se ejecuta la correlación parcial como método independiente. La matriz final obtenida mediante Graphical Lasso es simétrica y se interpreta como una red de dependencias estadísticas condicionadas.

3.6.3 LiNGAM

LiNGAM se utiliza como aproximación dirigida exploratoria para estimar posibles relaciones entre regiones cerebrales. Este método asume que las variables observadas pueden representarse mediante un modelo lineal acíclico con errores independientes no gaussianos [7]. Las variables corresponden a las señales BOLD regionales obtenidas a partir del atlas Schaefer 100. En la implementación presente no se realizó verificación formal de estos supuestos sobre los datos, lo que constituye una limitación adicional a la interpretación de los resultados de LiNGAM.

Para cada sujeto, LiNGAM estima una matriz de adyacencia dirigida:

$$\mathbf{M}^{\text{LiNGAM}} \in \mathbb{R}^{K \times K} \quad (4)$$

donde cada elemento M_{ij} representa un peso dirigido entre las regiones i y j . El pipeline transpone la matriz de adyacencia entregada por la librería para mantener la convención M_{ij} = influencia estimada desde la ROI origen i hacia la ROI destino j . Luego, cada matriz se divide por el mayor coeficiente absoluto del mismo sujeto. Por tanto, los valores usados en la comparación grupal son pesos relativos dentro de cada sujeto, acotados entre -1 y 1 , y no coeficientes causales crudos comparables en escala absoluta entre sujetos.

La interpretación de estas relaciones dirigidas sigue las restricciones descritas en la sección de Fundamentos, en particular las derivadas de la respuesta hemodinámica y de los supuestos no verificados del método.

3.7 Vectorización de matrices

Para utilizar las matrices de conectividad como entrada de los clasificadores, cada matriz se transforma en un vector de características. Cada elemento del vector representa una conexión entre dos ROIs,

excluyendo la diagonal principal, ya que esta corresponde a autococonexiones.

En correlación de Pearson y Graphical Lasso, las matrices son simétricas. Por ello se utiliza únicamente el triángulo superior de la matriz, evitando duplicar conexiones equivalentes entre pares de regiones. Esta representación resume las asociaciones funcionales estimadas para cada sujeto en un formato compatible con los clasificadores supervisados.

En LiNGAM, la matriz es dirigida y no se asume simetría. Por esta razón se consideran todos los elementos fuera de la diagonal, conservando la orientación definida por las salidas del pipeline. De esta forma, la vectorización mantiene la información direccional producida por el método.

Así, cada sujeto queda representado por un vector numérico específico para cada método de conectividad, que luego se utiliza para entrenar y evaluar los modelos de clasificación supervisada.

3.8 Clasificación

La tarea de clasificación consiste en distinguir TEA y controles utilizando como entrada los vectores de características obtenidos a partir de las matrices de conectividad. Para ello se emplean dos clasificadores supervisados implementados con pesos balanceados por clase: una máquina de soporte vectorial (SVM) con kernel RBF y un Random Forest de 300 árboles.

Para cada método de conectividad, los vectores de características son ingresados a ambos clasificadores bajo el mismo esquema de evaluación. De esta forma, se comparan las combinaciones entre método de conectividad y clasificador, manteniendo constante el procedimiento de entrenamiento y evaluación. Se reporta el desempeño de esta configuración fija del pipeline, sin presentar una búsqueda formal de hiperparámetros como resultado principal.

3.9 Evaluación y comparación entre métodos

El desempeño de los modelos se estima mediante validación cruzada estratificada agrupada por sitio de adquisición con cinco particiones (*StratifiedGroupKFold*). Este esquema busca preservar la proporción entre TEA y controles y, al mismo tiempo, evita que sujetos del mismo sitio de adquisición se mezclen entre entrenamiento y prueba dentro de una misma partición. Para cada combinación entre método de conectividad y clasificador se reportan métricas de clasificación binaria: *accuracy*, *balanced accuracy*, precisión, *recall*, especificidad, *F1-score* y AUC. Las cifras principales se calculan concatenando las predicciones *out-of-fold* de todos los sujetos; adicionalmente, el repositorio conserva medias y desviaciones estándar por fold. Estas métricas permiten evaluar distintos aspectos del rendimiento del modelo, tales como la proporción total de aciertos, la confiabilidad de las predicciones positivas, la capacidad de detectar sujetos con TEA, la identificación correcta de controles y la capacidad general de separación entre clases. Los intervalos de confianza del 95% se estiman mediante 2000 réplicas de *bootstrap* por sitio, usando las predicciones *out-of-fold*. El pipeline conserva además medias y desviaciones estándar por partición. El mismo esquema de evaluación se mantiene para Pearson, Graphical Lasso y LiNGAM, de modo que las diferencias observadas puedan atribuirse principalmente al tipo de matriz de conectividad utilizada como entrada.

El propósito comparativo considera los resultados obtenidos por los tres métodos de conectividad. Pearson y Graphical Lasso representan enfoques asociativos, mientras que LiNGAM representa una aproxi-

mación orientada a relaciones dirigidas. La comparación busca examinar si la incorporación de información direccional mediante LiNGAM aporta información complementaria frente a los métodos asociativos tradicionales en la tarea de clasificación de TEA y controles. Además del desempeño de clasificación, se considera la interpretación de las matrices obtenidas. En Pearson se analizan asociaciones lineales entre regiones; en Graphical Lasso se observan dependencias condicio-

das y redes más dispersas; mientras que en LiNGAM se exploran posibles relaciones dirigidas entre regiones cerebrales. Esta comparación permite discutir no solo el rendimiento predictivo, sino también el tipo de información neurofuncional capturada por cada enfoque. La Figura 2 resume la relación entre datos, parcelación, estimación de conectividad, inferencia grupal, visualización y clasificación.




Figura 2: Pipeline general. El flujo resume la entrada de datos rs-fMRI de ABIDE I, la parcelación con Schaefer 100 ROIs, la extracción de series temporales, la estimación mediante correlación de Pearson, Graphical Lasso y LiNGAM, el ajuste por covariables, la inferencia FDR/NBS y la evaluación de clasificación con SVM y Random Forest.

4 RESULTADOS

La cohorte final incluyó 723 sujetos de ABIDE I: 329 TEA y 394 controles, distribuidos en 17 sitios. Pearson y Graphical Lasso constituyen los resultados principales, mientras que LiNGAM completa la comparación entre representaciones de conectividad.

4.1 Descripción de la cohorte

La Tabla 1 resume la composición de la cohorte. La edad media fue similar, mientras que el grupo TEA presentó mayor FD medio, mayor porcentaje de volúmenes con FD y menor proporción de mujeres. Estas diferencias respaldan el ajuste por covariables antes de interpretar conexiones concretas. Las diferencias observadas en FD medio, proporción de mujeres y sitio de adquisición confirman la necesidad de controlar estas variables antes de interpretar diferencias de conectividad entre grupos.

Grupo	n	Edad	Mujeres	FD medio	CI total
Controles	394	16,81 (7,06)	84 (21,3 %)	0,10 (0,08)	111,26 (12,45)
TEA	329	17,30 (7,73)	44 (13,4 %)	0,12 (0,12)	106,21 (17,41)

Tabla 1: Resumen de covariables por grupo. Los valores continuos se expresan como media (DE). El CI estuvo disponible para 361 controles y 303 sujetos TEA.

4.2 Matrices promedio

Las Figuras 3 y 4 muestran las matrices promedio y la diferencia TEA – controles. Las regiones se ordenan por las siete redes funcionales del atlas Schaefer. Pearson produce matrices densas, mientras que Graphical Lasso, con $\alpha = 0,5$, genera una representación regularizada y más dispersa. Las matrices promedio de LiNGAM, presentadas en la Figura 8, muestran una estructura notablemente más dispersa y

con pesos de menor magnitud que los métodos asociativos, lo que es consistente con la normalización por sujeto aplicada. Mientras Pearson captura sincronía global densa y Graphical Lasso selecciona dependencias condicionales dispersas, LiNGAM representa pesos relativos de influencia dirigida sin escala absoluta comparable entre sujetos. Los conectomas de LiNGAM de la Figura 11 se presentan como referencia exploratoria; la proyección no preserva la dirección de las conexiones.




Figura 3: Matrices promedio y diferencia TEA – controles para correlación de Pearson, ordenadas por redes funcionales.




Figura 4: Matrices promedio y diferencia TEA – controles para Graphical Lasso, ordenadas por redes funcionales.

4.3 Inferencia estadística ajustada

Después del ajuste por edad, sexo, FD medio y sitio, 554 conexiones de Pearson y 10 conexiones de Graphical Lasso conservaron $q_{FDR} < 0,05$. La magnitud máxima de correlación parcial entre diagnóstico y conexión fue 0,237 para Pearson y 0,194 para Graphical Lasso.

NBS identificó un componente significativo de Pearson con 381 conexiones ($p_{NBS} = 0,004$) y cuatro componentes de Graphical Lasso que sumaron 31 conexiones ($p_{NBS} = 0,001$ para cada componente). La Figura 5 muestra únicamente las conexiones pertenecientes a esos componentes.

La conexión con mayor estadístico dentro del componente de Pearson unió regiones prefrontales bilaterales de la red de modo por defecto ($\beta = -0,123$ en escala z de Fisher; $t = -6,47$; $q_{FDR} < 10^{-6}$). Para

Graphical Lasso, la conexión principal unió regiones precuneus/PCC bilaterales de la red de modo por defecto ($\beta = -0,0218$; $t = -5,24$; $q_{FDR} = 0,001$). Los signos negativos indican menor conectividad ajustada en TEA.

La magnitud media de Pearson no conservó una diferencia ajustada tras FDR. Graphical Lasso mostró una reducción pequeña de magnitud en TEA ($q_{FDR} = 0,015$). La diferencia de esparsidad de Graphical Lasso no conservó significación después de corregir las seis comparaciones ($q_{FDR} = 0,099$). Estas métricas de magnitud y esparsidad a nivel grupal se complementan con las distribuciones por sujeto presentadas a continuación.

Los conectomas exploratorios de Pearson (Figura 9) ilustran la distribución espacial de las conexiones del componente NBS. Los conectomas de Graphical Lasso (Figura 10) muestran la concentración de conexiones significativas en regiones de la red de modo por defecto.




Figura 5: Componentes significativos identificados mediante NBS. Los colores representan el efecto ajustado TEA – controles.

4.4 Distribuciones por sujeto

La Tabla 2 y la Figura 6 presentan la magnitud absoluta media y la esparsidad calculadas en cada sujeto.

Método	Métrica	Controles	TEA	β_{TEA}	q_{FDR}
Pearson	Magnitud	0,3465 (0,1003)	0,3448 (0,1015)	−0,0128	0,130
Pearson	Esparsidad	0,0015 (0,0024)	0,0016 (0,0020)	0,0002	0,334
Graphical Lasso	Magnitud	0,0076 (0,0012)	0,0075 (0,0013)	−0,0003	0,015
Graphical Lasso	Esparsidad	0,8891 (0,0340)	0,8904 (0,0353)	0,0051	0,099

Tabla 2: Magnitud absoluta media y esparsidad calculadas por sujeto. Los valores grupales son media (DE); β_{TEA} está ajustado por edad, sexo, FD medio y sitio.

Distribuciones de conectividad calculadas por sujeto




Figura 6: Distribuciones por sujeto de magnitud absoluta media y esparsidad para Pearson y Graphical Lasso.

Las diferencias observadas a nivel de sujeto, aunque de magnitud modesta, sugieren que las matrices contienen variabilidad diferencial entre grupos, lo que motiva la evaluación supervisada presentada en la sección siguiente.

4.5 Resultados de clasificación

Se evalúa el desempeño de clasificación para los seis pares método-clasificador: Pearson, Graphical Lasso y LiNGAM, cada uno combinado con SVM y Random Forest.

La Tabla 3 incorpora *balanced accuracy*, AUC e intervalos de confianza obtenidos por *bootstrap* de sitios. Pearson con SVM presentó la mayor *balanced accuracy*: 0,640 (IC95 %: 0,589–0,675). Graphical Lasso con Random Forest obtuvo el mayor AUC: 0,686 (IC95 %:

0,632–0,738).

LiNGAM obtuvo *balanced accuracy* de 0,499 con SVM y 0,461 con Random Forest, además de AUC inferiores a 0,45. Este resultado negativo no respalda una ventaja predictiva de la representación dirigida. Este resultado es consistente con la ausencia descriptiva de diferencias grupales sistemáticas en las matrices promedio de LiNGAM (Figura 8), donde la normalización por sujeto elimina la comparabilidad absoluta entre coeficientes. La Figura 7 muestra las curvas ROC correspondientes.

En conjunto, Pearson y Graphical Lasso ofrecen información diferencial con desempeño moderado, mientras que LiNGAM no aporta ventaja predictiva en estas condiciones.

Método	Clasificador	Balanced accuracy (IC95 %)	AUC (IC95 %)	Recall	Especificidad
Pearson	SVM	0,640 (0,589–0,675)	0,674 (0,622–0,721)	0,559	0,721
Pearson	RF	0,595 (0,557–0,625)	0,650 (0,604–0,693)	0,401	0,789
Graphical Lasso	SVM	0,540 (0,507–0,576)	0,593 (0,549–0,661)	0,550	0,530
Graphical Lasso	RF	0,586 (0,556–0,626)	0,686 (0,632–0,738)	0,350	0,822
LiNGAM	SVM	0,499 (0,487–0,508)	0,443 (0,403–0,489)	0,052	0,947
LiNGAM	RF	0,461 (0,445–0,488)	0,438 (0,415–0,468)	0,207	0,716

Tabla 3: Clasificación de TEA y controles mediante predicciones out-of-fold. Los IC95 % se obtuvieron con 2000 réplicas de bootstrap por sitio.




Figura 7: Curvas ROC para la clasificación de TEA y controles.

5 DISCUSIÓN

5.1 Efecto del método de conectividad

La elección del estimador modifica la estructura y la interpretación de la red. Pearson resume sincronía lineal y conserva una matriz densa; Graphical Lasso regulariza la matriz de precisión y enfatiza dependencias condicionadas [3, 13]. Sus pesos no son intercambiables ni deben compararse como si pertenecieran a una escala común.

La inferencia ajustada mostró un componente amplio para Pearson y componentes más pequeños para Graphical Lasso. Esta diferencia es coherente con la regularización: Pearson conserva asociaciones distribuidas, mientras que Graphical Lasso selecciona una estructura más restringida. La convergencia de ambos métodos en conexiones de la red de modo por defecto, incluido el eje precuneus/PCC–prefrontal, es compatible con sistemas frecuentemente estudiados en TEA [21]. La interpretación permanece limitada a la cohorte y al modelo estadístico utilizado.

LiNGAM produjo una estructura diferente debido a su orientación dirigida y a la normalización independiente de cada matriz por sujeto. Esta representación no convergió descriptivamente con las conexiones de Pearson y Graphical Lasso concentradas en la red de modo por defecto, lo que puede reflejar tanto el tipo de información estimada como la pérdida de comparabilidad absoluta introducida por la normalización.

5.2 Covariables, movimiento y estabilidad

Las diferencias observadas en movimiento, sexo y cociente intelectual confirman la necesidad del ajuste. La inclusión de FD medio y

efectos fijos de sitio reduce confusión conocida en rs-fMRI, aunque no elimina por completo la heterogeneidad de protocolos, calidad de imagen o características clínicas [24, 25].

NBS aporta control por componentes conectados, pero sus resultados dependen del umbral primario $|t| \geq 3,1$. FDR y NBS responden preguntas complementarias: FDR controla pruebas por conexión, mientras que NBS evalúa la extensión de subredes supraliminales [27]. La replicación por sitio y la validación externa siguen siendo necesarias para evaluar estabilidad.

5.3 LiNGAM y clasificación

LiNGAM produjo matrices dirigidas, pero no mejoró la clasificación. Su *balanced accuracy* fue cercana o inferior a 0,5 y los AUC se ubicaron por debajo del azar. La señal BOLD es indirecta, suavizada y retardada; además, la normalización por sujeto conserva relaciones relativas y no coeficientes comparables en escala absoluta, y los supuestos de linealidad, aciclicidad y no gaussianidad no fueron verificados formalmente. Estas condiciones, señaladas en la sección de Fundamentos, limitan la capacidad discriminativa de la representación obtenida [7].

Los intervalos de confianza muestran incertidumbre entre sitios incluso para Pearson y Graphical Lasso. Pearson con SVM ofrece el mejor equilibrio entre clases, mientras que Graphical Lasso con Random Forest alcanza el mayor AUC pero presenta baja sensibilidad. LiNGAM con SVM presentó un *recall* extremadamente bajo (0,052) con especificidad alta (0,947), lo que indica que el clasificador aprendió a predecir casi siempre la clase mayoritaria. Este patrón sugiere que los vectores de características derivados de LiNGAM no proveen señal

discriminativa suficiente para el clasificador. Ninguna combinación constituye una herramienta diagnóstica. Una evaluación predictiva más exigente requeriría validación leave-one-site-out, ajuste anidado de hiperparámetros y una cohorte externa [17].

6 CONCLUSIÓN

El pipeline integra datos ABIDE I, parcelación Schaefer 100, matrices individuales, ajuste por covariables, inferencia FDR/NBS y validación de clasificación agrupada por sitio. La trazabilidad entre sujetos, señales, matrices, tablas y figuras permite reproducir las salidas principales.

Pearson y Graphical Lasso constituyen los resultados centrales. Pearson detectó un componente distribuido, mientras que Graphical Lasso identificó componentes más pequeños y una reducción leve de magnitud en TEA. Los tamaños de efecto fueron modestos y dependen del control de movimiento, sitio y covariables.

LiNGAM aportó una representación dirigida complementaria, pero su desempeño predictivo no superó el azar y no respalda una interpretación causal. La clasificación tampoco permite plantear uso clínico:

los intervalos de confianza y la variabilidad multicéntrica requieren validación externa.

El aporte principal es metodológico y reproducible. Las limitaciones incluyen heterogeneidad entre sitios, movimiento residual, datos faltantes de cociente intelectual, elección del umbral NBS, la elección exploratoria del parámetro de regularización α para Graphical Lasso sin validación cruzada formal y ausencia de una cohorte independiente. Las conclusiones se restringen a patrones de conectividad de la cohorte analizada, sin proponer biomarcadores ni causalidad demostrada.

Respecto de los objetivos específicos, las señales BOLD regionales se extrajeron para 723 sujetos mediante el atlas Schaefer 100; los tres métodos produjeron matrices con propiedades estructurales distintas y LiNGAM generó representaciones dirigidas no comparables en escala absoluta con los métodos asociativos; Pearson y Graphical Lasso identificaron componentes con diferencias ajustadas significativas, concentradas en la red de modo por defecto; y Pearson con SVM y Graphical Lasso con Random Forest ofrecieron el mejor desempeño preliminar, mientras que LiNGAM no superó el azar.

Referencias

- [1] World Health Organization, “Autism,” <https://www.who.int/news-room/fact-sheets/detail/autism-spectrum-disorders>, 2025, consultado el 15 de junio de 2026.
- [2] M. D. Fox and M. E. Raichle, “Spontaneous fluctuations in brain activity observed with functional magnetic resonance imaging,” *Nature Reviews Neuroscience*, vol. 8, no. 9, pp. 700–711, 2007.
- [3] S. M. Smith, D. Vidaurre, C. F. Beckmann, M. F. Glasser, M. Jenkinson, K. L. Miller, T. E. Nichols, E. C. Robinson, G. Salimi-Khorshidi, M. W. Woolrich, D. M. Barch, K. Ugurbil, and D. C. Van Essen, “Functional connectomics from resting-state fMRI,” *Trends in Cognitive Sciences*, vol. 17, no. 12, pp. 666–682, 2013.
- [4] K. J. Friston, “Functional and effective connectivity in neuroimaging: A synthesis,” *Human Brain Mapping*, vol. 2, no. 1–2, pp. 56–78, 1994.
- [5] J. Pearl, “Causal inference in statistics: An overview,” *Statistics Surveys*, vol. 3, pp. 96–146, 2009.
- [6] K. J. Friston, “Functional and effective connectivity: A review,” *Brain Connectivity*, vol. 1, no. 1, pp. 13–36, 2011.
- [7] S. Shimizu, P. O. Hoyer, A. Hyvärinen, and A. Kerminen, “A linear non-Gaussian acyclic model for causal discovery,” *Journal of Machine Learning Research*, vol. 7, pp. 2003–2030, 2006.
- [8] B. Biswal, F. Z. Yetkin, V. M. Haughton, and J. S. Hyde, “Functional connectivity in the motor cortex of resting human brain using echo-planar MRI,” *Magnetic Resonance in Medicine*, vol. 34, no. 4, pp. 537–541, 1995.
- [9] S. Ogawa, T.-M. Lee, A. R. Kay, and D. W. Tank, “Brain magnetic resonance imaging with contrast dependent on blood oxygenation,” *Proceedings of the National Academy of Sciences*, vol. 87, no. 24, pp. 9868–9872, 1990.
- [10] N. K. Logothetis, J. Pauls, M. Augath, T. Trinath, and A. Oeltermann, “Neurophysiological investigation of the basis of the fMRI signal,” *Nature*, vol. 412, no. 6843, pp. 150–157, 2001.
- [11] R. B. Buxton, E. C. Wong, and L. R. Frank, “Dynamics of blood flow and oxygenation changes during brain activation: The balloon model,” *Magnetic Resonance in Medicine*, vol. 39, no. 6, pp. 855–864, 1998.
- [12] A. Schaefer, R. Kong, E. M. Gordon, T. O. Laumann, X.-N. Zuo, A. J. Holmes, S. B. Eickhoff, and B. T. T. Yeo, “Local-global parcellation of the human cerebral cortex from intrinsic functional connectivity MRI,” *Cerebral Cortex*, vol. 28, no. 9, pp. 3095–3114, 2018.
- [13] J. Friedman, T. Hastie, and R. Tibshirani, “Sparse inverse covariance estimation with the graphical lasso,” *Biostatistics*, vol. 9, no. 3, pp. 432–441, 2008.
- [14] S. M. Smith, K. L. Miller, G. Salimi-Khorshidi, M. Webster, C. F. Beckmann, T. E. Nichols, J. D. Ramsey, and M. W. Woolrich, “Network modelling methods for FMRI,” *NeuroImage*, vol. 54, no. 2, pp. 875–891, 2011.
- [15] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [16] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [17] A. S. Heinsfeld, A. R. Franco, R. C. Craddock, A. Buchweitz, and F. Meneguzzi, “Identification of autism spectrum disorder using deep learning and the ABIDE dataset,” *NeuroImage: Clinical*, vol. 17, pp. 16–23, 2018.
- [18] D. M. W. Powers, “Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation,” *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.
- [19] T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.

- [20] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [21] A. Di Martino, C.-G. Yan, Q. Li, E. Denio, F. X. Castellanos, K. Alaerts, J. S. Anderson, M. Assaf, S. Y. Bookheimer, M. Dapretto, B. Deen, S. Delmonte, I. Dinstein, B. Ertl-Wagner, D. A. Fair, L. Gallagher, D. P. Kennedy, C. L. Keown, C. Keyzers, J. E. Lainhart, C. Lord, B. Luna, V. Menon, N. J. Minshew, C. S. Monk, S. Mueller, R.-A. Müller, M. B. Nebel, J. T. Nigg, K. O’Hearn, K. A. Pelphrey, S. J. Peltier, J. D. Rudie, S. Sunaert, M. Thioux, J. M. Tyszka, L. Q. Uddin, J. S. Verhoeven, N. Wenderoth, J. L. Wiggins, S. H. Mostofsky, and M. P. Milham, “The autism brain imaging data exchange: Towards a large-scale evaluation of the intrinsic brain architecture in autism,” *Molecular Psychiatry*, vol. 19, no. 6, pp. 659–667, 2014.
- [22] R. C. Craddock, Y. Benhajali, C. Chu, F. Chouinard, A. Evans, A. Jakab, B. S. Khundrakpam, J. D. Lewis, Q. Li, M. P. Milham, C.-G. Yan, and P. Bellec, “The neuro bureau preprocessing initiative: Open sharing of preprocessed neuroimaging data and derivatives,” *Frontiers in Neuroinformatics*, vol. 7, p. 27, 2013.
- [23] FCP-INDI, “C-PAC: Configurable pipeline for the analysis of connectomes,” Zenodo, 2017. [Online]. Available: <https://github.com/FCP-INDI/C-PAC>
- [24] J. D. Power, K. A. Barnes, A. Z. Snyder, B. L. Schlaggar, and S. E. Petersen, “Spurious but systematic correlations in functional connectivity MRI networks arise from subject motion,” *NeuroImage*, vol. 59, no. 3, pp. 2142–2154, 2012.
- [25] R. Ciric, D. H. Wolf, J. D. Power, D. R. Roalf, G. L. Baum, K. Ruparel, R. T. Shinohara, M. A. Elliott, S. B. Eickhoff, C. Davatzikos, R. C. Gur, R. E. Gur, D. S. Bassett, and T. D. Satterthwaite, “Benchmarking of participant-level confound regression strategies for the control of motion artifact in studies of functional connectivity,” *NeuroImage*, vol. 154, pp. 174–187, 2017.
- [26] Y. Benjamini and Y. Hochberg, “Controlling the false discovery rate: A practical and powerful approach to multiple testing,” *Journal of the Royal Statistical Society: Series B*, vol. 57, no. 1, pp. 289–300, 1995.
- [27] A. Zalesky, A. Fornito, and E. T. Bullmore, “Network-based statistic: Identifying differences in brain networks,” *NeuroImage*, vol. 53, no. 4, pp. 1197–1207, 2010.